

NGHIÊN CỨU CÁC MÔ HÌNH NHẬN DẠNG, PHÂN LOẠI CÁC KHỐI U VÚ ÁC TÍNH

Thông tin bài viết

Dạng bài viết:

Bài báo nghiên cứu khoa học sinh viên

*Tác giả liên hệ:

Địa chỉ E-mail:
banglh@utt.edu.vn

Giảng viên hướng dẫn:

Đoàn Thị Thanh Hằng¹

Giảng viên nhận xét:

Trần Đức Thắng¹

Nguyễn Huy Giang¹, Nguyễn Bá Duy¹, Hoàng Nhật Anh¹, Trần Mỹ Anh¹, Ngô Tiến Đạt¹

¹Lớp 74DCTT23 Khoa Công nghệ thông tin, Trường Đại học Công nghệ Giao thông Vận tải, 54 Triều Khúc, Thanh Liệt, Hà Nội

Tóm tắt: Nghiên cứu xây dựng hệ thống hỗ trợ nghiên cứu sàng lọc ung thư vú theo hai nhánh bằng chứng độc lập. Study A đánh giá Machine Learning trên 569 mẫu WDBC với 30 đặc trưng hình thái nhân tế bào từ FNA. Logistic Regression được lựa chọn dựa trên bằng chứng out-of-fold của tập phát triển, giữ xác suất thô và ngưỡng cố định 0,36; trên tập kiểm thử độc lập mô hình đạt ROC-AUC 0,9954, Sensitivity 0,9524 và Specificity 0,9861. Study B đánh giá ảnh nhũ ảnh CBIS-DDSM theo manifest chia nhóm study-like đã kiểm soát leakage và không còn giao nhau nhóm giữa các split. EfficientNet-B0 sử dụng ảnh full được chọn theo validation-first, đạt ROC-AUC 0,7229, Sensitivity 0,6786 và Specificity 0,6250 trên test; Platt scaling được dùng cho độ tin cậy hiển thị trong khi xác suất thô vẫn là tín hiệu quyết định. SHAP, Grad-CAM, bootstrap 95% CI và phân tích sai số được sử dụng để mô tả hành vi và độ bất định của mô hình. Hệ thống web FastAPI triển khai trực tuyến tích hợp phân tích ML, ảnh nhũ ảnh, báo cáo nghiên cứu và mô-đun fusion phần mềm 40/60. Do WDBC và CBIS-DDSM không phải dữ liệu ghép cặp, điểm fusion không được xem là mô hình đa phương thức y khoa đã được kiểm chứng.

Ghi chú: Bài báo là sản phẩm thuộc đề tài nghiên cứu khoa học sinh viên có mã đề tài: ĐTSV2526-278; Tên đề tài: “Nghiên cứu các mô hình nhận dạng, phân loại các khối u vú ác tính”

Từ khóa: Ung thư vú; WDBC; CBIS-DDSM; Machine Learning; Deep Learning; SHAP; Grad-CAM; hiệu chỉnh xác suất; FastAPI.

1. Giới thiệu

Ung thư vú là một trong những bệnh lý ác tính phổ biến ở nữ giới, trong đó phát hiện sớm có ý nghĩa quan trọng đối với khả năng can thiệp và tiên lượng. Trong nghiên cứu trí tuệ nhân tạo, bài toán này thường được tiếp cận từ hai nhóm dữ

liệu khác nhau: dữ liệu có cấu trúc mô tả đặc trưng tế bào và dữ liệu ảnh nhũ ảnh. Hai dạng dữ liệu yêu cầu các phương pháp mô hình hóa, đánh giá và giải thích khác nhau; vì vậy đề tài tổ chức thành hai study độc lập thay vì ghép các metric vào một bảng xếp hạng chung.

Study A sử dụng Wisconsin Diagnostic Breast

Cancer (WDBC), gồm 569 quan sát và 30 đặc trưng số được suy ra từ hình thái nhân tế bào FNA. Study B sử dụng ảnh nhũ ảnh CBIS-DDSM đã xử lý. Hệ thống tập trung không chỉ vào Accuracy mà còn vào Sensitivity, Specificity, ROC-AUC, PR-AUC, calibration, bootstrap confidence interval, false negative/false positive và khả năng giải thích. Cách tiếp cận này phù hợp với mục tiêu nghiên cứu: mô tả rõ hiệu năng và độ bất định thay vì chỉ trình bày một con số chính xác tổng thể.

Đề tài đồng thời triển khai các artifact nghiên cứu thành một hệ thống web end-to-end bằng FastAPI, HTML/CSS/JavaScript, SQLite, Docker Compose và Nginx. Website phục vụ trình diễn học thuật: nhập 30 đặc trưng WDBC, tải ảnh nhũ ảnh, xem kết quả dự đoán, SHAP/Grad-CAM, lịch sử và báo cáo. Hệ thống là Research/Educational Prototype, không phải thiết bị chẩn đoán y khoa và không thay thế bác sĩ.

Đóng góp chính của đề tài gồm: (1) quy trình WDBC có outer hold-out và development OOF để lựa chọn model/calibration/threshold; (2) quy trình CBIS-DDSM theo manifest study-like group với overlap train/validation/test bằng 0; (3) phân tích calibration, uncertainty và XAI cho các model đã đóng băng; (4) thí nghiệm ROI ablation theo tiêu chí validation-first; và (5) hệ thống web trực tuyến minh họa toàn bộ quy trình nghiên cứu.

2. Dữ liệu và phương pháp

2.1. Dữ liệu WDBC và giao thức Study A

WDBC gồm 569 mẫu: 212 malignant và 357 benign, với 30 đặc trưng số. Đề tài dùng seed 42 và stratified outer split: 455 mẫu cho development và 114 mẫu cho held-out test. Mọi quyết định về mô hình, calibration và threshold được thực hiện trên development bằng 5-fold stratified out-of-fold (OOF); tập test chỉ dùng mô tả cuối sau khi các quyết định đã được khóa.

Bảng 1. Thống kê dữ liệu và nguồn bằng chứng chính.

Study	Quy mô	Protocol
WDBC ML	569 mẫu; 30 features	455 development / 114 held-out test
CBIS-DDSM DL	2.559 full + 2.559 ROI	2.354 study-like groups; overlap = 0

Nhãn trong hệ thống được chuẩn hóa 1 = malignant, 0 = benign. Logistic Regression chứa bước chuẩn hóa trong pipeline. Random Forest và XGBoost được dùng làm mô hình so sánh. Tiêu chí lựa chọn candidate chính dựa trên bằng chứng development OOF, ưu tiên ROC-AUC, PR-AUC, balanced accuracy, calibration và số false negative; không chọn model bằng cách nhìn trước test set.

2.2. Dữ liệu CBIS-DDSM và kiểm soát leakage

Ảnh CBIS-DDSM được tổ chức theo manifest `cbis\_group\_split\_seed42.csv`. Manifest gồm 5.118 dòng, tương ứng 2.559 ảnh full đã xử lý và 2.559 biểu diễn ROI, thuộc 2.354 nhóm study-like suy ra từ tiền tố filename trước chuỗi “_”. Kiểm tra cho thấy số nhóm giao nhau giữa train-validation, train-test và validation-test đều bằng 0. Đây là conservative group split; do snapshot cục bộ không còn đầy đủ metadata bệnh nhân/case nên nghiên cứu không khẳng định patient-level independence tuyệt đối.

Các metric từ folder split cũ bị ảnh hưởng bởi leakage chỉ được xem là lịch sử phát triển và không được sử dụng trong bảng kết quả final. Quy trình final dùng manifest mới, seed 42, checkpoint theo validation và không dùng test-time augmentation cho kết quả chính.


2.3. Mô hình, calibration và đánh giá

Study A so sánh Logistic Regression, Random Forest và XGBoost. Study B so sánh Custom CNN, ResNet50 và EfficientNet-B0. Với ML, raw và Platt probabilities được so sánh trên development OOF; threshold được chọn trên OOF balanced accuracy. Với DL, EfficientNet-B0 full image là candidate được giữ lại theo

validation-first; Platt scaling được chọn cho reliability/display dựa trên validation, nhưng quyết định runtime dùng raw probability với ngưỡng cố định xấp xỉ 0,515.

Các metric gồm Accuracy, Precision, Sensitivity, Specificity, F1, Balanced Accuracy, ROC-AUC, PR-AUC và Brier score. Bootstrap 2.000 lần với seed 42 được dùng để mô tả khoảng tin cậy 95% cho candidate chính. Explainability sử dụng SHAP LinearExplainer cho Logistic Regression và Grad-CAM trên layer `top\_conv` cho EfficientNet-B0.

3. Kiến trúc hệ thống và luồng nghiên cứu



Research / Educational Prototype
Không dùng cho chẩn đoán lâm sàng

Hình 1. Kiến trúc triển khai của Breast Health Studio: trình duyệt → Nginx/HTTPS → Docker web/API → SQLite và model artifacts.

Kiến trúc tách rõ tầng nghiên cứu và tầng trình diễn. Frontend tĩnh gọi FastAPI; backend thực hiện xác thực, validation, inference, lưu lịch sử và sinh báo cáo; model artifacts được mount riêng và không đóng gói vào Git thông thường. Staging chạy qua HTTPS trên `staging.breastcare.click`. Health/readiness endpoint giúp xác nhận database và các frozen model đã sẵn sàng trước khi demo.


Hai nhánh phân tích trên giao diện được trình bày như hai evidence stream độc lập. Người dùng có thể chọn preset nghiên cứu hoặc tự nhập

dữ liệu. Branch 1 nhận 30 WDBC FNA nuclear morphology features bằng nhập tay hoặc CSV. Branch 2 nhận mammogram PNG/JPEG và chạy EfficientNet-B0 + Grad-CAM. Hệ thống không giả định hai input thuộc cùng một bệnh nhân.

4. Thực nghiệm và kết quả

4.1. Study A - Machine Learning trên WDBC

Logistic Regression được giữ làm primary ML candidate dựa trên development OOF: ROC-AUC 0,9950, PR-AUC 0,9941, balanced accuracy 0,9724, Brier score 0,0200 và 4 false negative trên OOF. Candidate giữ raw probability và threshold 0,36. Điểm quan trọng là quyết định này được đưa ra trước khi mô tả test set, vì vậy việc Random Forest có ROC-AUC test hơi cao hơn không làm thay đổi candidate.



Hình 2. So sánh hiệu năng held-out test của ba mô hình WDBC theo final protocol.

Bảng 2. Kết quả final trên held-out test WDBC.


Model	Acc.	Sens.	Spec.	ROC-AUC
Logistic Reg.	0,9737	0,9524	0,9861	0,9954
Random Forest	0,9649	0,9286	0,9861	0,9983
XGBoost	0,9649	0,9048	1,0000	0,9924

Trên 114 mẫu test, Logistic Regression dự đoán đúng 111 mẫu với 2 false negative và 1 false positive. Sensitivity 0,9524 cho thấy phần lớn mẫu malignant được phát hiện trong held-out test, trong khi Specificity 0,9861 thể hiện tỷ lệ false alarm thấp. Tuy nhiên, các con số này chỉ phản ánh WDBC trong protocol hiện tại và không được diễn giải như hiệu năng lâm sàng ngoài

Hình 5. Bootstrap 95% CI (2.000 lần) cho
Logistic Regression trên held-out test.

ROC-AUC của Logistic Regression là 0,9954 với bootstrap 95% CI xấp xỉ 0,9858-1,0000; balanced accuracy 0,9692 với CI khoảng 0,9299-1,0000. Khoảng tin cậy được trình bày để nhấn mạnh rằng mọi metric trên tập hữu hạn đều có độ bất định, ngay cả khi point estimate rất cao.

4.3. SHAP - giải thích nhánh WDBC




Hình 6. SHAP global summary của Logistic Regression: mean |SHAP| trên tập giải thích final.

SHAP LinearExplainer được dùng sau khi mô hình đã đóng băng. 'worst texture' có mean absolute SHAP lớn nhất (1,2576), tiếp theo là 'radius error', 'worst symmetry', 'compactness error' và 'mean concave points'. Đây là mô tả mức đóng góp của feature vào log-odds malignant của mô hình; không phải quan hệ nhân quả và không chứng minh một đặc trưng là yếu tố sinh học gây ung thư.

Phân tích local SHAP cũng được tạo cho các trường hợp TP, TN, FP và FN để quan sát nguyên nhân mô hình đẩy xác suất theo hướng nào. Ví dụ, trong một TP điển hình, 'worst texture' đóng góp dương mạnh; ngược lại ở một FN, nhiều feature có đóng góp âm kéo xác suất xuống dưới threshold. Các ví dụ sai số này hữu ích hơn việc chỉ trình bày feature importance toàn cục vì chúng cho thấy cơ chế dẫn tới lỗi cụ thể.

4.4. Study B - Deep Learning trên CBIS-DDSM


Dưới protocol leakage-controlled, EfficientNet-



Hình 3. Confusion matrix của Logistic Regression, Random Forest và XGBoost tại frozen threshold.


Confusion matrix bổ sung thông tin mà Accuracy không thể hiện: XGBoost đạt 0 false positive nhưng có 4 false negative; Logistic Regression có 2 false negative và 1 false positive. Trong bối cảnh hỗ trợ sàng lọc nghiên cứu, false negative được theo dõi riêng thay vì bị che bởi metric tổng hợp.

4.2. Calibration và độ bất định của ML




Hình 4. So sánh Brier score và ECE trên development OOF giữa raw và Platt probability.

Calibration được lựa chọn trước test. Logistic Regression giữ raw probability vì raw Brier = 0,0200 tốt hơn Platt Brier = 0,0213 dù Platt có ECE thấp hơn. Random Forest hưởng lợi từ Platt calibration, còn XGBoost giữ raw theo rule đã khóa. Cách tiếp cận này tránh hiệu chỉnh chỉ để làm đẹp một metric trên test.



B0 full processed images là kiến trúc được giữ lại theo validation-first. Final test đạt Accuracy 0,6480, Sensitivity 0,6786, Specificity 0,6250, Balanced Accuracy 0,6518, ROC-AUC 0,7229 và PR-AUC 0,6564. Kết quả cho thấy nhánh DL có khả năng phân biệt ở mức trung bình và còn 54 false negative; vì vậy các claim được giữ ở mức research-grade, không phải clinical performance.




Hình 7. So sánh final test Custom CNN, ResNet50 và EfficientNet-B0 trên CBIS-DDSM.

Bảng 3. Kết quả final của ba kiến trúc DL.


Model	Acc.	Sens.	Spec.	ROC-AUC
Custom CNN	0,568 9	0,458 3	0,651 8	0,615 3
ResNet50	0,545 9	0,720 2	0,415 2	0,627 8
EfficientNet -B0	0,648 0	0,678 6	0,625 0	0,722 9

ResNet50 đạt Sensitivity cao hơn EfficientNet-B0 nhưng Specificity thấp rõ rệt, tạo nhiều false positive. EfficientNet-B0 có discrimination tốt hơn trên validation và test, đồng thời cân bằng hơn giữa hai lớp, nên được giữ làm candidate chính. Candidate selection không dựa vào một metric test đơn lẻ.




Hình 8. Confusion matrix final của ba kiến trúc DL; EfficientNet-B0 có 54 FN và 84 FP.

4.5. Calibration, uncertainty và ROI ablation của DL




Hình 9. Reliability của EfficientNet-B0: Raw, Platt và Isotonic trên validation/test.

Platt scaling được chọn từ validation vì giảm Brier từ 0,2327 xuống 0,2118 và ECE từ 0,1139 xuống 0,0221. Trên test, Platt cũng giảm Brier còn 0,2088. Tuy vậy, calibration này phục vụ reliability/display; raw probability vẫn được dùng cho decision threshold để giữ đúng frozen inference contract.



Hình 10. Bootstrap 95% CI cho candidate EfficientNet-B0.


ROC-AUC 0,7229 có bootstrap 95% CI khoảng 0,6720-0,7722; balanced accuracy 0,6518 có CI khoảng 0,6024-0,7007. Độ rộng của các khoảng này cho thấy uncertainty còn đáng kể và hỗ trợ cách diễn giải thận trọng đối với nhánh ảnh.



Hình 11. ROI ablation trên validation: full image được giữ vì ROC-AUC và Sensitivity giảm khi chỉ dùng ROI.

Thí nghiệm ROI-C so sánh EfficientNet-B0 full và ROI theo tiêu chí được định trước. Trên validation, ROI làm ROC-AUC giảm từ 0,7044 xuống 0,6789 và Sensitivity giảm từ 0,6813 xuống 0,5125, dù Specificity tăng. Vì selection rule ưu tiên discrimination và screening sensitivity, ROI bị reject. Việc test ROI có một số metric hơi cao hơn không được dùng để đảo ngược quyết định validation-first; đây là ví dụ quan trọng về kiểm soát cherry-picking.

4.6. Grad-CAM - giải thích nhánh ảnh



Hình 12. Ví dụ trực quan ảnh nhũ ảnh và Grad-CAM của pipeline dự án (benign/malignant).


Grad-CAM của final EfficientNet-B0 được sinh sau model freeze trên layer `top\_conv`, với lựa chọn deterministic các ví dụ TP/TN/FP/FN. Heatmap cho thấy vùng kích hoạt mà mạng tập trung khi suy luận, giúp quan sát hành vi của

model và phát hiện các trường hợp chú ý bất thường. Heatmap không phải segmentation, không xác định ranh giới tổn thương và không được xem là pathology evidence.

Hình minh họa trên cho thấy cách hệ thống đặt heatmap bên cạnh ảnh đầu vào để người xem kiểm tra vùng attention. Trong báo cáo final, trọng tâm không phải “mô hình nhìn đúng vị trí ung thư” mà là “mô hình đang dựa vào vùng nào của ảnh”. Cách diễn giải này tránh gán ý nghĩa lâm sàng vượt quá khả năng của Grad-CAM.

5. Tích hợp thử nghiệm đa phương thức và hệ thống web

5.1. Scientific contract của Fusion




Hai bộ dữ liệu hoàn toàn không ghép cặp.
Điểm fusion không phải kết quả multimodal đã kiểm chứng.

Hình 13. Scientific contract của Experimental Fusion: hai study độc lập, phần mềm kết hợp 40/60.

Web có mô-đun Experimental Research Fusion nhận một bộ 30 WDBC features và một mammogram, sau đó tính $p_{fusion} = 0,4 \times p_{ML}(raw) + 0,6 \times p_{DL}(raw)$ với midpoint phần mềm 0,50. Công thức này chỉ là heuristic để minh họa integration. WDBC và CBIS-DDSM là hai dataset hoàn toàn unpaired; vì vậy một WDBC observation được chọn trong demo không phải thông tin của cùng người với mammogram được tải lên.

Khi hai branch mâu thuẫn, combined score không “giải quyết” được bất đồng khoa học. Giao diện giữ cảnh báo unpaired dataset và hiển thị

từng branch probability riêng để người xem thấy nguồn gốc của kết quả. Không có claim rằng fusion hiện tại tốt hơn ML-only hay DL-only.



Hình 14. Ví dụ kết quả Fusion trên staging: hai case agreement và hai case dùng mammogram tự tải lên.

Các ca staging cho thấy hệ thống vận hành end-to-end: Benign CSV + Benign demo mammogram cho combined score khoảng 0,291; Malignant CSV + Malignant demo khoảng 0,768. Khi dùng một mammogram tự tải lên, Benign WDBC tạo score khoảng 0,354 và branch disagreement; Malignant WDBC với cùng ảnh tạo score khoảng 0,718. Các ví dụ này chứng minh đường đi phần mềm, không phải benchmark đa phương thức.

5.2. Triển khai và kiểm thử hệ thống

Ứng dụng được triển khai trên Docker Compose phía sau host Nginx và HTTPS. API 8000 chỉ nằm trong internal network; web được public qua reverse proxy. Model artifact được mount read-only; dữ liệu SQLite, backup và kết quả ở các thư mục riêng. Upload mammogram hỗ trợ JPEG/PNG/WebP và giới hạn 20 MB. Sau khi phát hiện host Nginx dùng body-size mặc định 1 MB, staging được điều chỉnh riêng `client\_max\_body\_size 20m`, nhờ đó ảnh CBIS-DDSM 1,66 MB có thể đi qua đúng pipeline EfficientNet-B0 + Grad-CAM.

Regression gần nhất cho chức năng custom upload và CSV demos đạt 111 backend tests pass, 12 JS CSV integration tests pass và 7 live staging browser checks pass. Website có research demo benign/malignant cho cả WDBC và mammography, CSV round-trip 30/30 features, Google sign-in, role user/doctor bất biến sau khi tạo tài khoản, history/report và

health/readiness checks. Các chức năng này được xem là lớp trình diễn phục vụ giảng viên, không phải đóng góp khoa học chính.

Bảng 4. Tóm tắt kiểm thử bản web nghiên cứu.

Nhóm kiểm thử	Kết quả
Backend regression	111 passed, 0 failed
JS CSV integration	12/12 passed
Live staging browser QA	7/7 passed
Custom mammogram 1,66 MB	HTTP 200; Grad-CAM generated
Health / readiness	PASS

6. Thảo luận

6.1. Điểm mạnh và ý nghĩa của kết quả

Nhánh WDBC cho thấy một classical ML pipeline có thể đạt discrimination rất cao khi protocol được khóa trước test và calibration/threshold được đánh giá cẩn thận. Điểm đáng chú ý không chỉ là ROC-AUC gần 1,0 mà là quy trình chọn Logistic Regression dựa trên development OOF, phân tích FN/FP, bootstrap CI và SHAP. Điều này tạo nền tảng minh bạch hơn so với việc báo cáo duy nhất Accuracy.

Nhánh CBIS-DDSM khó hơn rõ rệt. EfficientNet-B0 đạt ROC-AUC khoảng 0,723, thấp hơn Study A nhưng hai con số không được so sánh trực tiếp vì modality, cohort và task context khác nhau. Giá trị của Study B nằm ở việc sửa leakage, dùng validation-first candidate selection, calibration, uncertainty, ROI ablation và Grad-CAM. Kết quả trung bình nhưng trung thực khoa học có ý nghĩa hơn metric cao xuất phát từ split không an toàn.

Việc triển khai web giúp chuyển các artifact nghiên cứu thành một môi trường demo có thể kiểm tra: người dùng thấy dữ liệu đầu vào, xác suất raw/calibrated, threshold, confusion/error context và XAI. Điều này hỗ trợ giảng viên quan sát mối liên hệ giữa nghiên cứu mô hình và kỹ nghệ phần mềm mà không làm thay đổi scientific contract của các study.

Thứ nhất, CBIS-DDSM hiện chỉ đảm bảo study-like group separation dựa trên filename prefix; chưa có đủ metadata để khẳng định patient-level independence tuyệt đối. Thứ hai, cả WDBC và CBIS-DDSM chưa có external validation độc lập trong repository hiện tại. Thứ ba, nhánh DL có discrimination mức trung bình và số false negative còn đáng kể. Thứ tư, SHAP và Grad-CAM chỉ là post-hoc explainability: SHAP không causal và Grad-CAM không phải lesion localization. Cuối cùng, WDBC và CBIS-DDSM không paired, vì vậy weighted fusion chỉ là software demonstration.

Các hạn chế trên được hiển thị trực tiếp trên website và được giữ trong báo cáo để tránh diễn giải quá mức. Hệ thống không được mô tả là công cụ chẩn đoán, không xác minh credential bác sĩ và không đưa ra khuyến nghị điều trị.

7. Kết luận và hướng phát triển

Đề tài đã hoàn thiện một quy trình nghiên cứu và trình diễn AI hỗ trợ sàng lọc ung thư vú theo hai study độc lập. Trong WDBC, Logistic Regression là primary candidate được chọn development-first, với held-out ROC-AUC 0,9954 và threshold 0,36. Trong CBIS-DDSM, EfficientNet-B0 full processed images là retained candidate theo validation-first, với test ROC-AUC 0,7229; Platt scaling cải thiện reliability và Grad-CAM hỗ trợ quan sát attention. ROI-only representation bị loại theo tiêu chí validation dù một số test metric có thể cao hơn.

Hệ thống web FastAPI/Docker/Nginx đã tích hợp các frozen research artifacts thành demo trực tuyến, hỗ trợ CSV, mammogram upload, SHAP/Grad-CAM, history/report và experimental fusion. Tuy nhiên, các kết luận cuối vẫn được giới hạn theo modality; fusion 40/60 không được coi là đóng góp multimodal đã kiểm chứng.

Hướng phát triển tiếp theo gồm: bổ sung metadata patient/case cho split CBIS-DDSM ở mức bệnh nhân; external validation cho cả hai study; đánh giá robustness/subgroup; và chỉ nghiên cứu multimodal khi có dataset tabular-image ghép cặp hợp lệ. Với mục tiêu hiện tại là báo cáo và trình diễn học thuật, hệ thống đã đạt

trạng thái đủ để giảng viên tái hiện các luồng nghiên cứu chính trên web.

Tài liệu tham khảo

- [1] UCI Machine Learning Repository, "Breast Cancer Wisconsin (Diagnostic) Data Set."
- [2] R. S. Lee et al., "A curated mammography data set for use in computer-aided detection and diagnosis research," Scientific Data, 2017.
- [3] L. Breiman, "Random Forests," Machine Learning, 2001.
- [4] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," Proc. KDD, 2016.
- [5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," Proc. CVPR, 2016.
- [6] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," Proc. ICML, 2019.
- [7] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," Advances in Neural Information Processing Systems, 2017.
- [8] R. R. Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," Proc. ICCV, 2017.
- [9] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On Calibration of Modern Neural Networks," Proc. ICML, 2017.
- [10] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, 2011.